

MaestroAI

Documento Técnico — v2

Versión 2 · 2026 · Documento confidencial

1. Resumen y alcance de la v2

Consolida la implementación real frente al blueprint: incorpora lo construido de más, especifica lo pendiente y añade casos de uso por área. Novedad de ingesta v2: extracción de texto de PDF/DOCX (OCR opcional).

2. Blueprint → implementación (scorecard)

Elemento del blueprint	Estado
Privacy Model Router (PUBLIC/INTERNAL/CONFIDENTIAL/RESTRICTED)	Hecho
Minimizar / anonimizar / auditar	Hecho
MVP: login, chat+RAG, carga segura, router, dashboard auditoría/costo	Hecho
Agentes: Document Intelligence, Cyber, Proposal/SOW, Executive Copilot	Hecho
Arquitectura por capas + multi-tenant	Hecho
Modelo de datos (tenants, users, agents, documents, chunks, ..., audit)	Hecho
6 workflows operativos (Ingesta, RAG, SOW, Cyber, Centro de mando, Fine-tuning)	Hecho (n8n)
Cifrado AES-256 en reposo + KMS por tenant; RBAC	Hecho
Model adapters (OpenAI-compatible, Ollama, vLLM, NaN, premium) · cost meter	Hecho
Export DOCX/PDF · security tests (injection, exfil, PII, cross-tenant)	Hecho
Ingesta: extracción de texto de PDF/DOCX	Hecho (v2)
Ingesta: antivirus (EICAR + ClamAV opcional) + tope de tamaño	Hecho (v2)
Ingesta: OCR de escaneados (tesseract en la imagen)	Hecho (v2)
MFA (TOTP) + códigos de respaldo, exigido en login	Hecho (v2)
Fine-tuning LoRA: andamiaje (datasets/anonimización/gate/jobs)	Hecho (v2)
Fine-tuning LoRA: entrenamiento real en GPU	Parcial (trainer externo/lab)
Confidential computing / TEE · mTLS / private endpoints	Pendiente (infra)

3. Construido más allá del blueprint

- Cascada NaN → premium (premium solo a demanda) + eficiencia/condensación de tokens.
- Reranking del RAG (Qwen3-Reranker) para más precisión.

- Toolkit de acciones de ESCRITURA (Gmail/Outlook, Calendar, Sheets/Excel, Teams) con aprobación humana.
- Multi-cuenta de correo; contenedor de documentos por área + categorías + tratamiento.
- Memoria + etiquetas; Notebooks; Flujogramas navegables; Generar imágenes.
- Conectores legados (BD de solo lectura, CSV) → RAG; «ojito» de secretos auditado.
- Verificación de proveedor (Probar conexión); Ayuda in-app + ayuda contextual (popup).
- Pipeline dev → qa → main con CI (pytest + build) y bitácora (CHANGELOG).

4. Casos de uso por área (vista técnica)

Ventas

Propuesta comercial en minutos

Objetivo: Generar una propuesta lista para enviar a partir de datos mínimos.

Módulo / ruta: Casos de uso · RAG (categoría propuesta_comercial) · Export

Valor: De horas a minutos, con marca y datos citados.

Pasos:

- 1 Casos de uso → Propuesta comercial.
- 2 Pon cliente, servicio, monto y notas.
- 3 Revisa el borrador (cita propuestas previas del RAG) y aprueba.
- 4 Descarga en Word/PDF.

Resumen de correo y agenda del día

Objetivo: Empezar el día con lo importante de la bandeja y el calendario.

Módulo / ruta: Toolkit lecturas (correo/calendar) · Router de privacidad

Valor: Menos tiempo en bandeja, foco en lo que vende.

Pasos:

- 1 Integraciones → Conectar correo (Outlook/Gmail).
- 2 Casos de uso → Resumen de correo y agenda.
- 3 Genera el resumen (PII redactada) y descárgalo.

Responder una licitación/RFP

Objetivo: Construir el borrador de respuesta a unas bases.

Módulo / ruta: Notebooks · RAG

Valor: Respuestas completas y trazables a las bases.

Pasos:

- 1 Notebooks → nuevo; sube las bases.
- 2 Genera FAQ y borrador de respuesta citando las bases.
- 3 Pasa el borrador a un caso de uso para el entregable final.

Seguimiento: correo + alta de lead en CRM

Objetivo: Enviar el follow-up y registrar el lead sin salir de la plataforma.

Módulo / ruta: Toolkit de acciones (aprobación) · Conectores

Valor: Cero doble captura; todo auditado.

Pasos:

- 1 Acciones → Enviar correo (Outlook/Gmail) → aprobar.
- 2 Integraciones → Conector HubSpot/Salesforce → enviar el lead.

Recursos Humanos

Cartas y contratos laborales

Objetivo: Generar oferta, carta o contrato con plantilla y datos del colaborador.

Módulo / ruta: Casos de uso · Export

Valor: Documentos consistentes y con marca.

Pasos:

- 1 Casos de uso → Carta/Contrato.
- 2 Llena los datos; revisa y aprueba.
- 3 Descarga en Word/PDF.

Consultas de políticas internas

Objetivo: Responder dudas del personal con base en el reglamento e ISO.

Módulo / ruta: RAG por área · Chat con fuentes

Valor: Respuestas correctas y citadas, sin abrir manuales.

Pasos:

- 1 Documentos → sube reglamento/políticas (área RH).
- 2 Chat con fuentes → elegir documentos → pregunta.
- 3 La respuesta cita el documento exacto.

Criba y resumen de CVs (con privacidad)

Objetivo: Resumir y comparar CVs respetando datos personales.

Módulo / ruta: Router de privacidad (PII) · RAG

Valor: Agiliza reclutamiento sin exponer PII a la nube.

Pasos:

- 1 Documentos → sube los CVs (el router los trata como confidenciales/PII).
- 2 Chat con fuentes → pide un resumen comparativo.

Onboarding automatizado

Objetivo: Disparar el checklist y la comunicación al alta de un colaborador.

Módulo / ruta: Automatizaciones · n8n

Valor: Onboarding uniforme y sin olvidos.

Pasos:

- 1 Automatizaciones → plantilla de onboarding.
- 2 Acción: notificar / workflow n8n / correo.

Finanzas

Reporte financiero / análisis

Objetivo: Generar un reporte a partir de cifras y notas.

Módulo / ruta: Fuentes de datos (BD/CSV) · Casos de uso · Export

Valor: Reportes con datos reales y formato listo.

Pasos:

- 1 Integraciones → Importar CSV/BD con las cifras (al RAG).
- 2 Casos de uso → Reporte; aprueba.
- 3 Exporta a XLSX/PDF.

Consultar datos de un sistema legado

Objetivo: Preguntar sobre datos de un ERP/BD sin API moderna.

Módulo / ruta: Conector BD de solo lectura · RAG

Valor: Acceso a datos legados sin riesgo de escritura.

Pasos:

- 1 Integraciones → Fuentes de datos → DSN + SELECT (solo lectura) → Importar.
- 2 Chat con fuentes → pregunta sobre esos datos.

Cobranza semanal automatizada

Objetivo: Recordatorios y reporte de cobranza cada semana.

Módulo / ruta: Automatizaciones (programadas)

Valor: Proceso recurrente sin intervención.

Pasos:

- 1 Automatizaciones → programada (semanal).
- 2 Acción: workflow/conector/correo.

Datos sensibles siempre protegidos

Objetivo: Garantizar que CLABE/tarjetas no salgan a la nube.

Módulo / ruta: Router de privacidad

Valor: Cumplimiento y tranquilidad por diseño.

Pasos:

- 1 Trabaja normal; el router detecta PII financiera y la mantiene en ruta privada.
- 2 Verifica la ruta en el banner y en Auditoría.

Operaciones

Reporte de operación / KPIs

Objetivo: Ver y reportar el pulso operativo.

Módulo / ruta: Tableros · Casos de uso

Valor: Decisiones con datos en vivo.

Pasos:

- 1 Tableros → describe qué medir; agrega widgets en vivo.
- 2 Casos de uso → Reporte de operación; exporta.

Procedimientos (SOP) con IA

Objetivo: Consultar y resumir manuales y procedimientos.

Módulo / ruta: Notebooks · RAG

Valor: Conocimiento operativo accesible al instante.

Pasos:

- 1 Notebooks → sube los SOP.
- 2 Genera una guía o pregunta con cita.

Alertas por evento

Objetivo: Reaccionar cuando ocurre algo (p. ej. documento crítico).

Módulo / ruta: Automatizaciones · Webhooks

Valor: Respuesta inmediata a eventos clave.

Pasos:

- 1 Automatizaciones → disparador por evento (document_uploaded) o webhook entrante.
- 2 Acción: notificar / workflow.

Integrar sistemas propios

Objetivo: Conectar herramientas a la medida sin API moderna.

Módulo / ruta: Conectores · n8n

Valor: Orquestación con el ecosistema existente.

Pasos:

- 1 Integraciones → Conector REST / Webhook / n8n.
- 2 Prueba y conéctalo a una automatización.

Proyectos

Generar un SOW / enunciado de trabajo

Objetivo: Crear un SOW metodológico a partir del input comercial.

Módulo / ruta: Agente Proposal/SOW · Workflow SOW

Valor: SOWs consistentes y rápidos.

Pasos:

- 1 Agentes → Proposal/SOW.
- 2 Da el contexto; revisa y exporta a PDF/Word.

Briefing y cronología del proyecto

Objetivo: Resumir documentos del proyecto en artefactos útiles.

Módulo / ruta: Notebooks

Valor: Arranque y handoff de proyecto más claros.

Pasos:

- 1 Notebooks → sube los documentos del proyecto.
- 2 Genera briefing y cronología.

Diagnóstico y roadmap

Objetivo: Evaluar (p. ej. ciberseguridad) y proponer un plan.

Módulo / ruta: Agente Cyber Diagnostic

Valor: Diagnóstico ejecutivo accionable.

Pasos:

- 1 Agentes → Cyber Diagnostic (u otro).
- 2 Responde el cuestionario; obtén riesgos + roadmap.

Seguimiento: eventos y tareas

Objetivo: Agendar y dar seguimiento desde la plataforma.

Módulo / ruta: Toolkit de acciones · Conectores

Valor: Menos saltos entre apps.

Pasos:

- 1 Acciones → Crear evento (Calendar) → aprobar.
- 2 Conector para crear tareas en tu herramienta.

Dirección General

Resumen ejecutivo y tableros

Objetivo: Ver uso, costo, riesgos y documentos en un vistazo.

Módulo / ruta: Dashboard · Tableros

Valor: Visión 360 del negocio y de la IA.

Pasos:

- 1 Resumen → panel ejecutivo.
- 2 Tableros → costo por ruta de modelo, casos por receta, etc.

Auditoría y cumplimiento

Objetivo: Demostrar control y trazabilidad ante auditoría.

Módulo / ruta: Auditoría · Export SIEM

Valor: Evidencia para cumplimiento (LFPDPPP).

Pasos:

- 1 Auditoría → filtra por riesgo/ruta/usuario.
- 2 Export SIEM (JSONL).

Decidir con memoria de trabajos

Objetivo: Retomar y construir sobre trabajos previos.

Módulo / ruta: Memoria + tags

Valor: Continuidad y aprovechamiento del conocimiento.

Pasos:

- 1 Memoria → busca por tag/tema.
- 2 Chat → activa «Usar memoria».

Control del costo de IA

Objetivo: Mantener el gasto bajo control sin perder calidad.

Módulo / ruta: Eficiencia · Cascada

Valor: Costo predecible; premium solo cuando aporta.

Pasos:

- 1 Admin → Eficiencia: tope de gasto, condensación, rerank.
- 2 Cascada: premium solo a demanda.

5. Pendientes por construir (especificación v2)

Fine-tuning LoRA — entrenamiento real en GPU

Qué: Conectar el andamiaje (ya hecho: datasets/anonimización/gate/jobs) a un trainer con GPU que entrene el adapter y lo sirva.

Por qué: El software ya está; falta el backend de cómputo (GPU) y servir el adapter (Ollama/vLLM).

Cómo: Trainer (servidor GPU / App NaN / webhook n8n) que recibe el JSONL, entrena PEFT/LoRA y hace callback; servir como ruta local/VPC. Ver docs/FINETUNING-SETUP.md.

Dependencias: GPU (local o NaN) + PEFT/transformers; Ollama/vLLM para servir.

Endurecimiento enterprise — TEE / mTLS / private endpoints

Qué: Confidential computing (TEE) para clientes regulados, mTLS entre servicios y endpoints privados.

Por qué: Fase 5: clientes regulados y VPC dedicada.

Cómo: Despliegue en VPC dedicada, mTLS entre servicios, enclaves/confidential VMs; no-retención contractual.

Dependencias: Infraestructura (nube/VPC) y contratos con proveedores.

6. Guías de configuración (resumen)

Microsoft 365 (Azure)

- 1 Azure → App registrations → New registration (cuentas org + personales).
- 2 Redirect URI Web: <https://oauth/microsoft/callback>.
- 3 Graph Delegated: User.Read, Mail.Read, Calendars.Read, offline_access (+ escritura: Mail.Send, Calendars.ReadWrite, ChannelMessage.Send, Files.ReadWrite.All, Sites.Read.All).

- 4 Crea client secret; pon MICROSOFT_* en Render; reconecta una vez.

Google Workspace

- 1 Cloud Console → habilita Gmail/Calendar/Drive/Sheets API.
- 2 OAuth consent + scopes (readonly + gmail.send, spreadsheets).
- 3 OAuth client (Web) con redirect https://oauth/google/callback; pon GOOGLE_* en Render.

NaN (open) y Premium

- 1 Admin → Modelos externos: Base URL + modelo + API key.
- 2 NaN: https://api.nan.builders/v1, modelo qwen3.6. Pulsa Probar conexión.
- 3 Premium: opcional, solo se usa como escalada (máxima precisión).

Ollama (local privado)

- 1 Instala Ollama y descarga un modelo (LOCAL_MODEL).
- 2 Exponlo con URL pública (cloudflared en prueba; servidor HTTPS en prod).
- 3 Pon LOCAL_* en Render; ALLOW_CLOUD_FALLBACK=true mientras no haya local.

n8n / Rerank / Ramas

- 1 n8n: Admin → n8n (Webhook Base URL + API key) o N8N_* en Render.
- 2 Rerank: Admin → Eficiencia → activar (requiere NaN).
- 3 Proteger ramas: GitHub → Settings → Branches → ruleset en main y qa (PR + checks).

7. Seguridad y cumplimiento

- Cifrado AES-256-GCM por tenant; redacción de PII; minimización de contexto.
- Auditoría total + export SIEM; permisos por área y licencia; multi-tenant.
- LFPDPPP · OWASP Top 10 LLM 2025 · NIST AI RMF.